

INFORME TÉCNICO

Segmentación Municipal: Perfiles Socioeconómicos e Inversión Pública

Análisis de Clústeres con K-Means y
Autocorrelación Espacial LISA (Moran Local)

Cobertura: 1,123 municipios de Colombia
Fuentes: SECOP II · DANE · TerriData · CNPV 2018
Metodología: K-Means · PCA · LISA (libpysal/esda)
Fecha: Abril 2026

Equipo de Análisis de Datos · Desarrollo Social y Económico

Índice

1. Resumen Ejecutivo	2
2. Descripción de los Datos	2
2.1. Fuentes de información	2
2.2. Preprocesamiento	3
2.3. Variables de entrada al modelo de clústeres	4
3. Metodología	4
3.1. Análisis de Autocorrelación Espacial (LISA)	4
3.2. Segmentación K-Means	4
3.3. Etiquetado automático de perfiles	5
4. Resultados	5
4.1. Análisis LISA de Inversión Pública	5
4.2. Perfiles K-Means ($K^* = 4$)	6
4.2.1. Descripción de cada clúster	6
4.3. Proyección PCA y separabilidad de clústeres	7
5. Implicaciones de Política	7
6. Municipios de Referencia por Clúster	8
6.1. Top 5 — Clúster 0 (mayor NBI dentro del clúster)	9
6.2. Top 5 — Clúster 1 (mayor inversión)	9
6.3. Top 5 — Clústeres 2 y 3 (mayor vulnerabilidad)	9
7. Limitaciones y Trabajo Futuro	10
8. Conclusiones	10
Anexo: Entorno Tecnológico	11

1. Resumen Ejecutivo

Hallazgos principales

Este análisis clasifica los municipios colombianos en cuatro perfiles distintos combinando indicadores de pobreza (NBI, IPM) con el volumen y eficiencia de la inversión pública registrada en SECOP II (2018–2025). Los resultados revelan una profunda heterogeneidad territorial y señalan brechas críticas de cobertura contractual que afectan prioritariamente a municipios de alta vulnerabilidad.

El presente informe documenta la metodología y los resultados de un proceso de segmentación municipal en dos etapas complementarias: (i) detección de autocorrelación espacial mediante el índice de Moran Local (**LISA**) sobre el monto per cápita de inversión pública, y (ii) agrupamiento no supervisado mediante **K-Means** sobre un conjunto multidimensional de variables socioeconómicas e indicadores de inversión.

Los principales hallazgos son:

- El algoritmo K-Means con $k = 4$ clústeres óptimos (coeficiente de silueta máximo) permite distinguir perfiles cualitativamente diferenciados.
- **967 municipios** (86 %) pertenecen al clúster *Consolidado + Bien Invertido*, con NBI mediano del 15,28 %.
- **148 municipios** (13 %) presentan NBI mediano superior al 49 % y registran monto total de contratos igual a cero, configurando una situación de alta vulnerabilidad y ausencia de inversión pública formal.
- El índice de Moran Global ($I = 0,034$, $p = 0,09$) sugiere una autocorrelación espacial positiva débil pero consistente con la hipótesis de concentración geográfica de la inversión.

2. Descripción de los Datos

2.1. Fuentes de información

El análisis integra cinco fuentes de datos públicas mediante cruces por código DIVIPOLA municipal:

Cuadro 1: Fuentes de datos utilizadas en el análisis

Fuente	Contenido	Periodo / Versión
SECOP II	Contratos públicos: monto, número, tipo de entidad	2018–2025
NBI (CNPV)	Necesidades Básicas Insatisfechas por componente	CNPV 2018
IPM (CNPV)	Índice de Pobreza Multidimensional total	CNPV 2018
EMICRON / CE-NU	Establecimientos educativos y económicos	Datos.gov.co
TerriData	Indicadores territoriales agregados	Datos.gov.co
Etnia (CNPV)	Composición étnica municipal	CNPV 2018

2.2. Preprocesamiento

Previo al análisis de clústeres se aplicaron los siguientes pasos de preparación:

1. **Normalización de identificadores:** el código DIVIPOLA se estandarizó a 5 dígitos con ceros a la izquierda.
2. **Conversión de tipos:** todas las variables de inversión se forzaron a tipo numérico; los valores no convertibles se reemplazaron por NaN.
3. **Transformación logarítmica:** las variables de inversión (`monto_total_contratos`, `num_contratos`, `eficiencia_inversion`, `ticket_promedio`) se transformaron con $\log(1 + x)$ para reducir la asimetría positiva.
4. **Imputación por mediana:** los valores faltantes remanentes (tras descartar filas con más del 50 % de variables nulas) se imputaron con la mediana de cada variable.
5. **Estandarización z:** todas las variables se escalaron a media cero y desviación estándar unitaria antes del ajuste del modelo.

2.3. Variables de entrada al modelo de clústeres

Cuadro 2: Variables incluidas en el modelo K-Means

Variable	Descripción	Transformación
NBI (%)	Prop. personas en NBI	Ninguna
ipm_total	IPM total municipal	Ninguna
monto_total_contratos	Monto total contratado	$\log(1 + x)$
num_contratos	Número de contratos	$\log(1 + x)$
etnia_indigena_pct	% población indígena	Ninguna
etnia_afro_pct	% población afrocolombiana	Ninguna
eficiencia_inversion	Monto / NBI	$\log(1 + x)$
ticket_promedio	Monto promedio por contrato	$\log(1 + x)$

3. Metodología

3.1. Análisis de Autocorrelación Espacial (LISA)

El índice de Moran Local (LISA) evalúa, para cada unidad territorial i , si su valor de inversión per cápita z_i se asocia estadísticamente con los valores de sus vecinos. Formalmente:

$$I_i = z_i \sum_j w_{ij} z_j \quad (1)$$

donde w_{ij} es el elemento de la matriz de pesos espaciales que refleja la vecindad entre los municipios i y j . Dado que las coordenadas geográficas reales no se encontraban disponibles en los datos, la vecindad se aproximó mediante un **proxy basado en el código DIVIPOLA**, asumiendo que municipios con códigos adyacentes comparten frontera administrativa.

Cada municipio significativo ($p < 0,05$) se clasificó en una de cuatro categorías:

- **High-High (HH)**: alta inversión rodeada de alta inversión.
- **Low-Low (LL)**: baja inversión rodeada de baja inversión.
- **High-Low (HL)**: alta inversión rodeada de baja inversión.
- **Low-High (LH)**: baja inversión rodeada de alta inversión.

3.2. Segmentación K-Means

El algoritmo K-Means minimiza la inercia intraclúster:

$$J = \sum_{k=1}^K \sum_{x_i \in C_k} \|x_i - \mu_k\|^2 \quad (2)$$

La selección del número óptimo de clústeres K^* se realizó mediante dos criterios complementarios evaluados para $k \in \{2, \dots, 8\}$:

- **Método del codo:** identificación del punto de inflexión en la curva de inercia.
- **Coeficiente de silueta:** $s(i) = (b(i) - a(i)) / \max\{a(i), b(i)\}$, donde $a(i)$ es la distancia media al propio clúster y $b(i)$ la distancia media al clúster más cercano.

Ambos criterios convergieron en $K^* = 4$ clústeres. El modelo final se ajustó con `n_init=10` inicializaciones aleatorias y semilla `random_state=42` para garantizar reproducibilidad.

3.3. Etiquetado automático de perfiles

Cada clúster fue etiquetado automáticamente comparando sus medianas de NBI e inversión con las medianas globales:

Cuadro 3: Matriz de etiquetado de perfiles

		NBI mediano	
		Alto	Bajo
Inversión mediana	Alto	Vulnerable + Bien Invertido	Consolidado + Bien Invertido
	Bajo	Vulnerable + Sub-invertido	Consolidado + Baja Inversión

4. Resultados

4.1. Análisis LISA de Inversión Pública

Cuadro 4: Distribución de municipios por categoría LISA ($p < 0,05$)

Categoría	N municipios	%	Interpretación
High-High (HH)	2	0,18	Núcleos de alta inversión concentrada
High-Low (HL)	6	0,53	Outliers de alta inversión
Low-High (LH)	35	3,11	Outliers de baja inversión
Low-Low (LL)	1,081	96,17	Clúster dominante de baja inversión
Total significativos	1,124	100	

Moran Global

$I_{\text{global}} = 0,0338$, $p = 0,090$. La autocorrelación espacial es positiva pero marginalmente significativa al nivel $\alpha = 0,10$. Este resultado debe interpretarse con cautela dado el uso de un proxy DIVIPOLA en lugar de coordenadas geográficas reales; la incorporación de un shapefile oficial podría modificar la estructura de vecindades y el estadístico resultante.

La composición casi total de clústeres LL (96 %) confirma que la inversión pública formal canalizada a través de SECOP II está altamente concentrada en un número reducido de municipios. Solo 8 municipios presentan patrones de alta inversión estadísticamente significativos.

4.2. Perfiles K-Means ($K^* = 4$)

Cuadro 5: Perfil mediano de cada clúster K-Means

Clúster	Etiqueta	N mun.	NBI med. (%)	IPM med.	Monto me
0	Consolidado + Bien Invertido	967	15,28	38,35	
1	Consolidado + Bien Invertido	8	10,10	29,10	
2	Vulnerable + Bien Invertido	79	49,96	61,10	
3	Vulnerable + Bien Invertido	69	49,49	70,40	
Total		1,123			

4.2.1. Descripción de cada clúster

Clúster 0 — Consolidado + Bien Invertido (967 municipios, 86 %) Agrupa la gran mayoría de los municipios del país. Presenta un NBI mediano relativamente moderado (15,28 %) y un IPM de 38,35. Sin embargo, el monto mediano de contratos es cero, lo que refleja que la mayoría de municipios de este clúster no tienen registros de contratación en SECOP II —posiblemente porque la inversión se ejecuta desde niveles departamentales o nacionales y no queda registrada a nivel municipal.

Clúster 1 — Consolidado + Bien Invertido (8 municipios) Subgrupo pequeño pero diferenciado: los mejores indicadores de desarrollo (NBI del 10,10 %, IPM del 29,10 %) y el único clúster con inversión mediana positiva (252,9 millones de pesos). Incluye municipios como **Maceo** (Antioquia, \$711,5M), **El Dovio** (Valle del Cauca, \$355,9M) y **Barbosa** (Antioquia, \$150M). Estos municipios constituyen candidatos naturales a *casos de estudio* de buenas prácticas en inversión pública.

Clústeres 2 y 3 — Vulnerable + Bien Invertido (148 municipios) Ambos clústeres concentran municipios de alta vulnerabilidad ($\text{NBI} \approx 50 \%$, $\text{IPM} > 60$) con monto de contratos igual a cero. Los municipios más vulnerables se encuentran en departamentos como Bolívar, Chocó, Nariño, Guainía y Vaupés. Destacan negativamente

San Jacinto (Bolívar, NBI = 93,4 %), Puerto Colombia ANM (Guainía, NBI = 96,0 %) y Pacoa ANM (Vaupés, NBI = 93,6 %).

Hallazgo crítico

Los clústeres 2 y 3 reúnen 148 municipios con NBI mediano cercano al 50 % y **cero registros de inversión en SECOP II**. Esto puede obedecer a: (a) ejecución presupuestal concentrada en entidades nacionales o departamentales no desagregadas municipalmente, (b) limitaciones en la capacidad de contratación local, o (c) subregistro en el sistema. Independientemente de la causa, representa una brecha de información pública que compromete la evaluación de política.

4.3. Proyección PCA y separabilidad de clústeres

La proyección bidimensional por Análisis de Componentes Principales (PCA) permite visualizar la separación entre clústeres. El panel PCA generado en el análisis muestra que:

- Los clústeres 2 y 3 se superponen parcialmente en el espacio PCA, lo que sugiere que su distinción proviene fundamentalmente de la variable IPM, cuya varianza es capturada en componentes de orden superior.
- El Clúster 1 (8 municipios) aparece como una nube compacta y claramente separada del resto, respaldando la coherencia interna de ese grupo.
- El Clúster 0 ocupa la mayor parte del espacio, con cierta dispersión propia de su heterogeneidad interna.

5. Implicaciones de Política

A partir de los perfiles identificados se derivan las siguientes recomendaciones diferenciadas por clúster:

Cuadro 6: Recomendaciones de política por clúster

Clúster	Perfil	Recomendación
0	Consolidado + Bien Invertido (967 mun.)	Sostener la trayectoria de desarrollo. Explorar si la ausencia de contratos SECOP refleja otra modalidad de ejecución y cerrar la brecha de información. Candidatos a modelos de buenas prácticas administrativas.
1	Consolidado + Bien Invertido (8 mun.)	Documentar y sistematizar experiencias exitosas de gestión contractual. Promover intercambio de buenas prácticas con municipios de clústeres más vulnerables.
2	Vulnerable + Bien Invertido (79 mun.)	Mantener la inversión actual; evaluar la eficiencia e impacto real sobre indicadores de NBI e IPM. Verificar si el registro nulo en SECOP oculta contratación departamental o nacional asignada al municipio.
3	Vulnerable + Bien Invertido (69 mun.)	Misma prioridad que Clúster 2. La mayor concentración en territorios indígenas (Guainía, Vaupés) sugiere revisar marcos diferenciales para territorios con regímenes especiales (ANM).

Recomendación transversal

Se recomienda enriquecer el dataset con las coordenadas geográficas oficiales del IGAC para reemplazar el proxy DIVIPOLA en el análisis LISA. Adicionalmente, cruzar los datos de SECOP II con el FUT (Formulario Único Territorial) permitiría distinguir entre ausencia real de inversión y subregistro por modalidad de ejecución.

6. Municipios de Referencia por Clúster

6.1. Top 5 — Clúster 0 (mayor NBI dentro del clúster)

Cuadro 7: Municipios con mayor NBI en Clúster 0

Departamento	Municipio	NBI (%)	Contratos (\$)
Bolívar	Clemencia	84,94	0
Córdoba	Canalete	75,38	0
Bolívar	Santa Rosa	70,91	0
Magdalena	Nueva Granada	68,55	0
Bolívar	Norosí	66,33	0

6.2. Top 5 — Clúster 1 (mayor inversión)

Cuadro 8: Municipios del Clúster 1 ordenados por NBI (desc.)

Departamento	Municipio	NBI (%)	Contratos (\$M)
Antioquia	Arboletes	62,49	28,1
Valle del Cauca	El Dovio	16,70	355,9
Antioquia	Anza	16,33	130,0
Antioquia	Maceo	13,18	711,5
Antioquia	Barbosa	7,01	150,0

6.3. Top 5 — Clústeres 2 y 3 (mayor vulnerabilidad)

Cuadro 9: Municipios más vulnerables en Clústeres 2 y 3

Clúster	Departamento	Municipio	NBI (%)	Contratos (\$)
2	Bolívar	San Jacinto	93,44	0
2	Chocó	Istmina	83,96	0
2	Nariño	Magüí	82,51	0
2	Nariño	La Tola	82,30	0
2	Antioquia	Murindó	81,73	0
3	Guainía	Puerto Colombia ANM	95,96	0
3	Vaupés	Pacoa ANM	93,65	0
3	Guainía	La Guadalupe ANM	93,63	0
3	Guainía	Pana Pana ANM	93,60	0
3	Guainía	Morichal ANM	92,37	0

7. Limitaciones y Trabajo Futuro

1. **Proxy espacial:** la ausencia de coordenadas geográficas reales implica que la estructura de vecindades LISA puede no reflejar la geografía física de Colombia. Se recomienda incorporar el shapefile municipal del IGAC para replicar el análisis.
2. **Monto de contratos:** la variable `monto_total_contratos` solo captura contratos registrados en SECOP II a nivel municipal. La inversión ejecutada mediante entidades nacionales (e.g., departamentos de policía, INVIAS, ICBF) no se refleja en estos datos.
3. **Etiquetado de clústeres:** el esquema de etiquetado automático compara medianas dentro del conjunto de clústeres, no con umbrales de política externos. Un análisis de política riguroso debería contrastar los valores medianos con estándares nacionales (e.g., umbral de NBI del 30 % para declarar pobreza estructural).
4. **Evolución temporal:** el análisis es de corte transversal. Incorporar la dimensión temporal (panel 2018–2025) permitiría identificar municipios en transición entre perfiles.
5. **Número óptimo de clústeres:** aunque el coeficiente de silueta apunta a $K^* = 4$, un análisis de sensibilidad con $K \in \{5, 6\}$ podría revelar subgrupos de política relevantes dentro del Clúster 0, que concentra el 86 % de los municipios.

8. Conclusiones

El análisis de segmentación municipal revela una estructura clara de heterogeneidad territorial en Colombia respecto a la relación entre pobreza e inversión pública formal:

- La **mayoría de municipios** (Clúster 0, 86 %) presentan indicadores de pobreza moderados pero no registran inversión a través de SECOP II, lo que podría indicar tanto buen funcionamiento de la asignación presupuestal centralizada como limitaciones en la capacidad contractual local.
- Un **grupo pequeño pero destacable** (Clúster 1, 8 municipios) combina bajos indicadores de pobreza con inversión formal activa, perfilándose como referentes de gestión pública eficiente.
- Los **clústeres de alta vulnerabilidad** (2 y 3, 148 municipios) presentan la paradoja más preocupante: NBI superiores al 80 % en los casos extremos, pero cero contratos registrados en SECOP II. Esta situación exige una investigación específica sobre los mecanismos de financiación que llegan —o no llegan— a estos territorios.
- El análisis LISA refuerza estos hallazgos mostrando que la inversión formal no presenta patrones de contigüidad espacial significativos: el 96 % de los municipios analizados caen en el cuadrante Low-Low, lo que descarta la existencia de polos regionales de inversión generalizables al resto del territorio.

Anexo: Entorno Tecnológico

Cuadro 10: Librerías y versiones utilizadas

Librería	Versión	Uso principal
Python	3.12.0	Lenguaje base
pandas	2.3.2	Manipulación de datos
numpy	1.26.4	Cómputo numérico
scikit-learn	1.7.1	K-Means, PCA, silueta
libpysal	4.14.1	Matriz de pesos espaciales
esda	2.9.0	Índice de Moran Local
geopandas	1.1.3	Manejo de geometrías
matplotlib	—	Visualización
scipy	1.16.1	Funciones estadísticas

Este informe fue generado a partir del análisis contenido en el cuaderno `deteccion_de_clusters.ipynb`. Los resultados son reproducibles con las fuentes de datos y el entorno tecnológico descritos en el Anexo.